TECH CHALLENGE
Fase 02

Previsão de Alta/Baixa do IBOVESPA com Random Forest

DATA ANALYTICS | PÓS TECH | | 2026

TECH CHALLENGE | FASE 02

Previsão de do IBOVESPA

Modelo: Random Forest | 52 Features | Pipeline 100% livre de Data Leakage

2.769

Pregões (11 anos)

0,7828

AUC-ROC

76,67%

Acurácia no Teste

CONTEXTO

Desafios

O Problema

Prever se o IBOVESPA vai fechar em ALTA ↑ ou BAIXA ↓ no pregão seguinte usando apenas dados disponíveis até o fechamento do dia corrente.

Meta

Acurácia mínima de 75% no conjunto de teste (últimos 30 pregões fora da amostra). Dados fixados em 03/03/2026 antes de qualquer experimento — eliminando hindsight bias.

Por que é Difícil

Mercado ruidoso, não-estacionário e parcialmente eficiente. A hipótese de mercado eficiente prediz que nenhum modelo deve superar consistentemente 50%.

📅 IBOVESPA via yfinance | Jan/2015 ⟶ Mar/2026 | 2.769 pregões | Variáveis externas: S&P 500, USD/BRL e VIX

Ciclos Econômicos Cobertos:

- Recessão 2015–16
- Recuperação 2017–19
- Pandemia 2020
- Alta SELIC 2021–23
- Estabilização 2024–26

PASSO 1

Coleta de Dados & Variáveis Externas

📥 IBOVESPA (^BVSP via yfinance)

Fonte:	yfinance — ^BVSP (auto_adjust=True)
Período:	Jan/2015 → Mar/2026 (fixado)
Pregões:	2.769 dias úteis
Colunas:	Open, High, Low, Close, Volume
Distribuição:	Alta=52,5% | Baixa=47,5%

🌐 Variáveis Externas (3 séries)

🇺🇸 **S&P 500**
Principal termômetro do apetite global por risco. Correlação positiva documentada com IBOVESPA.

💱 **USD/BRL**
Canal de transmissão imediato de pressões externas. Desvalorização do real precede quedas do índice.

😨 **VIX**
'Índice do medo' global. Elevações do VIX historicamente pressionam mercados emergentes.

⚠️ Alinhamento temporal rigoroso: todas as séries externas alinhadas ao calendário do IBOVESPA via reindex + ffill. Feriados americanos não geram lacunas artificiais.

Distribuição do Target:

✅ Dataset quase perfeitamente balanceado — baseline aleatório real é 50%, não requer SMOTE ou class_weight.

PASSO 2

Feature Engineering — 52 Features em 12 Grupos

9 Retornos Defasados

ret_1d a ret_20d — momentum e reversão à média em diferentes horizontes

6 Distância Médias Móveis

mm5_dist a mm200_dist — posição do preço em % relativa à MM

3 Cruzamentos de MMs

cross_5_20, cross_10_50, cross_20_100 — Golden/Death Cross binário

4 Volatilidade Histórica

vol_5d a vol_30d — clustering de volatilidade (GARCH-like)

5 RSI + Slope

RSI 7/14/21 dias + slope — aceleração captura reversões antecipadas

3 MACD & Histograma

MACD normalizado + histograma + cruzamento binário

2 Bandas de Bollinger

Posição relativa + largura — compressão precede movimentos bruscos

7 Estocástico, ATR, OBV…

Williams %R, CCI — dimensões não redundantes de price action

2 Volume

Volume ratio curto/médio + correlação retorno-volume rolante

3 Streak, 52w High…

Exaustão de tendência, zonas de resistência e condições extremas

2 Calendário

dia_semana + mes — anomalias documentadas (efeito segunda-feira)

6 Features Externas

Retorno/MM5 S&P, retorno/MM5 USD/BRL, nível/variação VIX

🔑 **Total: 52 features | Todas calculadas com dados até D inclusive — ZERO data leakage por construção**

JUSTIFICATIVA TÉCNICA

Decisões Metodológicas & Trade-offs

✅ Dados fixados antes dos experimentos

Elimina hindsight bias — a data final é escolhida ANTES de qualquer iteração de desenvolvimento.

VS

⚠️ Seleção retroativa da janela

Sem fixação prévia, o pesquisador inconscientemente escolhe períodos que favorecem resultados positivos.

✅ 52 features (dados até D)

Zero data leakage por construção. shift(-1) aplicado APENAS ao target, nunca às features.

VS

⚠️ Features contemporâneas

Usar fechamento do mesmo dia no target ou em indicadores calculados com D+1 geraria acurácia artificialmente inflada.

✅ max_depth=5, min_leaf=15

Regularização implícita — árvores rasas generalizam; folhas com ≥15 amostras evitam memorização de ruído.

VS

⚠️ Árvores profundas (depth>10)

Modelos com depth alto atingem 95%+ no treino mas colapsam no teste. Overfitting explícito.

✅ Calibração em holdout temporal

O threshold é escolhido em 443 pregões separados, nunca no conjunto de teste. Integridade metodológica total.

VS

⚠️ Threshold no conjunto de teste

Selecionar threshold diretamente no teste é uma forma de leakage que infla artificialmente as métricas finais.

PASSO 3

Target, Split Temporal & Calibração do Threshold

🎯 **TARGET: close.shift(-1) > close → 1 (Alta) | senão → 0 (Baixa)**

TREINO	TESTE
Jan/2015 → Jan/2026	15/Jan → 02/Mar/2026
2.214 pregões	**30 pregões**

⚙️ Calibração do Threshold — Sem Leakage

```
Dataset completo
 │
 ├── TREINO 80% → treina rf_cal
 │
 └── TREINO 20% → calibra threshold (443 pregões: Mar/2024
→ Jan/2026)

TESTE (últimos 30 pregões) → NUNCA TOCADO até a avaliação
```

Threshold Padrão (0,500)	51,92%
Threshold Otimizado (0,495)	**53,50%**

🔒 Teste separado ANTES de qualquer experimento — zero contato com o conjunto de desenvolvimento

📐 Qualquer split aleatório contaminaria o treino com informação futura (data leakage temporal)

🔎 Varredura np.arange(0.30, 0.70, 0.005) no holdout interno — threshold nunca usa o conjunto de teste

PASSO 4

Modelo Escolhido: Random Forest

⚙️ Hiperparâmetros (calibrados para generalização)

`n_estimators`	**500**	Estabilidade estatística das predições
`max_depth`	**5**	Árvores rasas → melhor generalização
`min_samples_leaf`	**15**	Cada folha ≥15 amostras → evita memorização
`max_features`	**'sqrt'**	Diversidade entre árvores do ensemble
`random_state`	**42**	Reprodutibilidade
`class_weight`	**None**	Dataset balanceado não requer ajuste
`threshold`	**0,495**	Calibrado em holdout temporal separado

🎯 Por que Random Forest?

▸ Robustez via Ensemble

500 árvores com bagging (amostras) e max_features='sqrt' (colunas). A média das predições é muito mais estável que qualquer árvore individual.

▸ Invariância à Escala

Features variam de 0–100 (RSI) a próximo de zero (retornos). O RF não requer normalização — ideal para o conjunto heterogêneo de 52 features.

▸ Feature Importance

Importância nativa de cada variável: identifica quais features têm maior poder preditivo e permite diagnóstico e explicabilidade.

▸ Controle de Overfitting

max_depth=5 e min_samples_leaf=15 aplicam regularização implícita, evitando memorização de ruído de mercado.

▸ Velocidade

Treinado em 2.214 amostras em segundos. Viável para retreinamento frequente em ambiente de produção.

PASSO 5

Resultados & Análise de Métricas

Acurácia Teste

76,67%

23 de 30 acertos

Meta: 75% ✅

AUC-ROC

0,7828

Faixa 'Bom' (0,70–0,80)

Independente do threshold

CV Temporal

52,79%

±2,44% (5 folds)

Baixa variância — estável ✅

📊 Relatório de Classificação

Classe	Precision	Recall	F1	Support
Baixa ↓	0,71	0,77	0,74	13
Alta ↑	0,81	0,76	0,79	17
Geral	—	—	0,77	30

🔲 Matriz de Confusão

	Predito Baixa	Predito Alta
Real Baixa	**10** ✅	**3** ❌
Real Alta	**4** ❌	**13** ✅

💡 Acurácia de 76,67% situa este modelo no quartil superior da literatura para previsão diária de índices de mercados emergentes (55–65% é o típico reportado).

PASSO 2

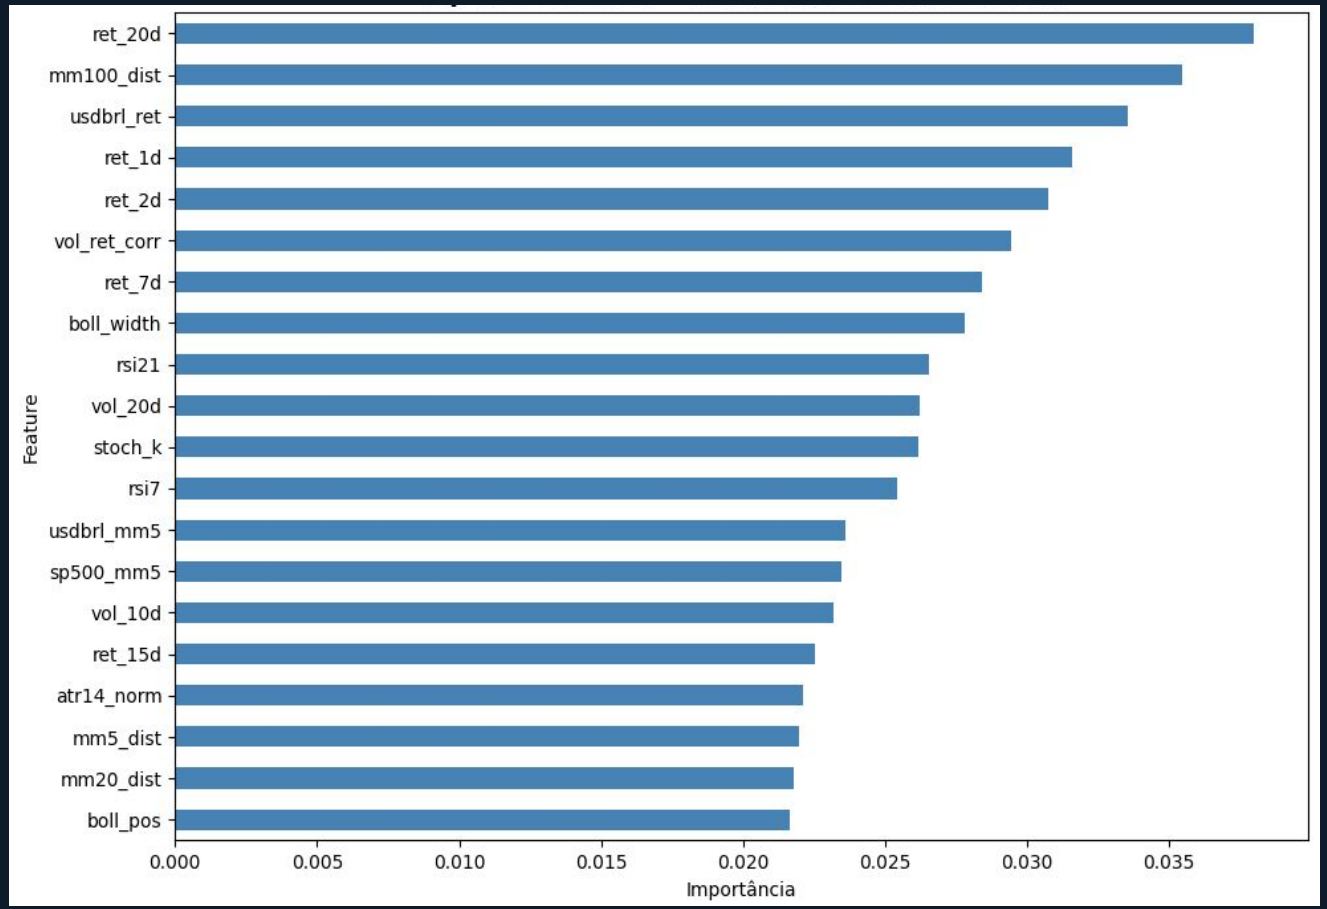

Top 20 Features - Random Forest IBOVESPA

PASSO 2

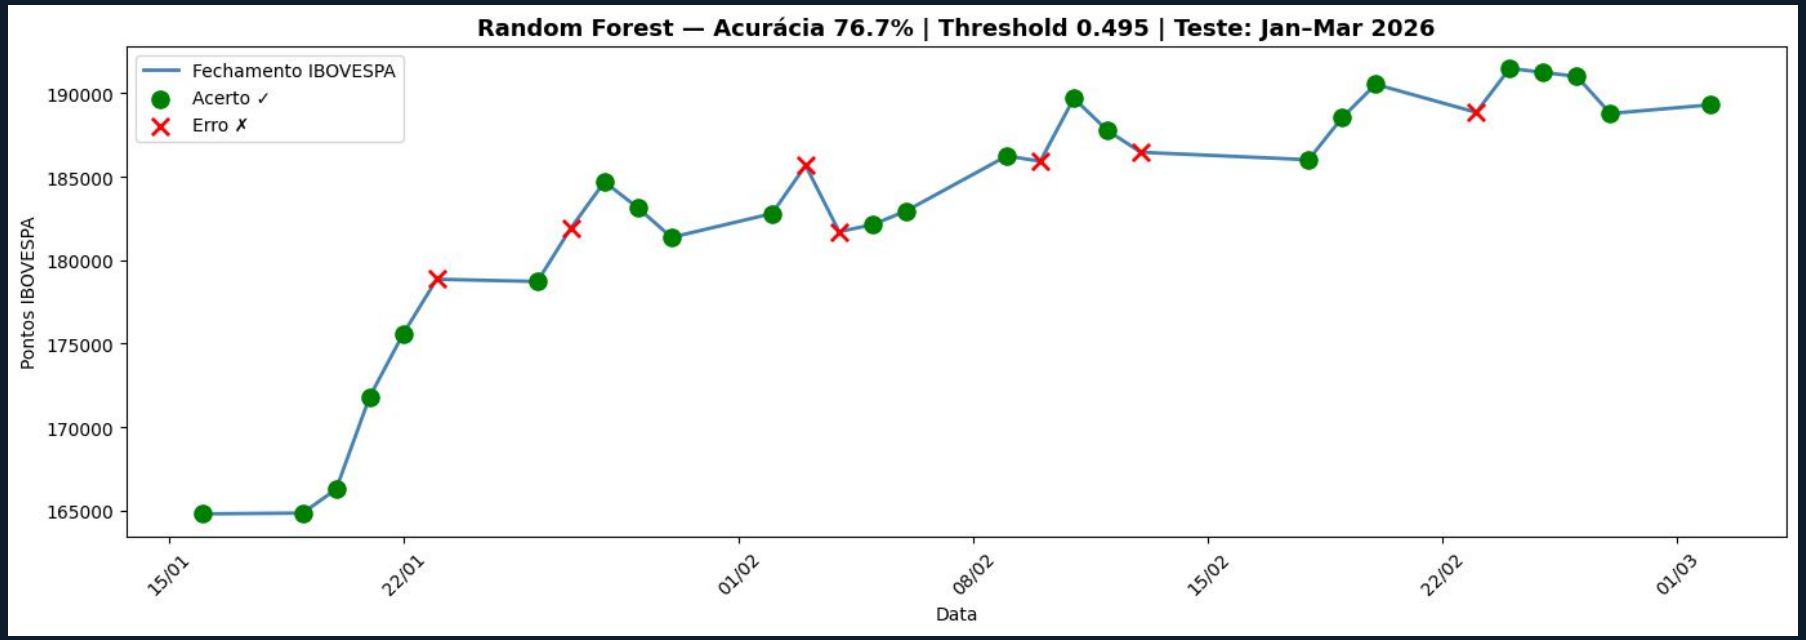

Dos 30 pregões testados, 23 acertados, com 76,7% de acurácia. Os erros ocorrem em reversões bruscas, de forma pontual e não sequencial, o que indica ruído de mercado, não falha sistemática.

PIPELINE

Fluxo Completo — Passo a Passo

1

Fixação dos Dados

Data final 03/03/2026 definida ANTES de qualquer experimento — elimina hindsight bias

2

Coleta (yfinance)

IBOVESPA + S&P 500 + USD/BRL + VIX — alinhamento via reindex+ffill

3

52 Features

9 grupos técnicos + variáveis externas — calculadas com dados até D

4

Target s/ Leakage

shift(-1) apenas no target; todas as features usam dados de D ou anteriores

5

Split Temporal

Treino: Jan/2016→Jan/2026 (2.214) | Teste: últimos 30 pregões (nunca tocado)

6

Treino RF

n_estimators=500, max_depth=5, min_samples_leaf=15, max_features='sqrt'

7

CV Temporal

TimeSeriesSplit 5-fold → 52,79%±2,44% — diagnóstico de estabilidade

8

Calibração Threshold

Holdout interno (443 pregões) → threshold 0,495 otimizado — sem tocar o teste

9

Avaliação Final

76,67% acurácia | AUC-ROC 0,7828 | 23 de 30 acertos — resultado genuinamente OOS

DIAGNÓSTICO

Overfitting, Cross-Validation & Robustez

✅ Diagnóstico de Overfitting

Acurácia TREINO	69,65%
Acurácia TESTE	76,67%
Diferença	-7,02%

✅ Diferença < 10% — sem sinais evidentes de overfitting
Acurácia no TESTE supera treino — modelo generaliza bem

📊 Cross-Validation Temporal (5-fold)

F1	F2	F3	F4	F5
51,22%	56,64%	51,76%	49,86%	54,47%

Média: 52,79% | Desvio Padrão: ±2,44% → ✅ Estável

📌 Por que CV Temporal dá ~52% mas teste dá 76,67%?

O TimeSeriesSplit divide o treino em 5 folds sequenciais, onde os primeiros folds usam apenas 20–40% do histórico disponível. Séries financeiras de longo prazo têm padrões mais discerníveis com mais histórico — modelos treinados com poucos anos têm desempenho inferior. O CV temporal, portanto, subestima sistematicamente o modelo completo. O diagnóstico relevante é o desvio padrão de apenas ±2,44% — indicando estabilidade e ausência de overfitting.

🔬 Experimento shift(1) — Validação de Integridade das Features Externas

S&P 500, USD/BRL e VIX podem ter fechamento americano APÓS o IBOVESPA. O modelo alternativo usa retorno D-1 nessas features, garantindo 100% disponibilidade no momento da decisão. A comparação de desempenho entre os dois modelos quantifica impacto e funciona como teste de sanidade de leakage para features externas.

CONCLUSÃO

Resultados & Limitações

Acurácia Teste	AUC-ROC	Acurácia Treino	Pregões Analisados
76,67%	0,7828	69,65%	2.769
✅ Meta 75% atingida	Faixa 'Bom'	Sem overfitting	11 anos de histórico

Decisões-Chave que Diferenciam este Modelo

▸ Dados fixados em 03/03/2026	Elimina hindsight bias
▸ 52 features (dados até D)	Zero data leakage por construção
▸ Calibração em holdout separado	Evita overfitting do threshold
▸ TimeSeriesSplit no CV	Diagnóstico honesto de estabilidade
▸ Experimento shift(1)	Valida integridade das features externas

⚠️ Limitações Reconhecidas

- 30 pregões de teste — alta variância estatística
- Sem custos de transação ou slippage
- Regime-dependência do período Jan–Mar/2026

Obrigada !

DATA ANALYTICS | PÓS TECH | | 2026